

Uso de Estruturas Competitiva de Redes Neurais Auto Associativas na Classificação de Tipos de Vinho

Luiz Henrique P. Assunção¹ e Paulo Vinícius Nobre Normando²

^{1 2}Faculdade de Engenharia Elétrica e Biomédica, Universidade Federal do Pará,
Av. Augusto Correa 01, Belém, Pará 66075-090, Brasil

Autor Correspondente¹: luiz.heinrich@live.com

Autor Correspondente²: paulonormando@gmail.com

Resumo

Nós estudamos duas arquiteturas de Redes Neurais Artificiais para o problema de classificação de três tipos de vinhos, com a finalidade de comparar a acurácia das duas redes no problema de classificação proposto. A primeira arquitetura estudada é uma rede mais simples, a Perceptron de Múltiplas Camadas (MLP), e já a segunda é uma Estrutura Competitiva de MLP Auto Associativa. O banco de dados é composto de 178 instâncias de 13 parâmetros das 3 classes de vinho. Primeiramente, nós normalizamos as entradas do banco de dados e implementamos os algoritmos das duas arquiteturas no software MATLAB. Como resultado, podemos identificar através do estudo do erro que a arquitetura de Competição Auto Associativa obteve um melhor desempenho para a classificação proposta do que a rede Perceptron de Múltiplas Camadas.

Palavras-chave: Redes Neurais Artificiais. Redes Auto Associativas. Vinho. MATLAB.

1 INTRODUÇÃO

As Redes Neurais Artificiais (RNA) são modelos matemáticos-computacionais que visam simular o comportamento e arquitetura de um neurônio biológico. Essa característica confere a uma RNA a capacidade de reconhecer e classificar padrões a partir de um modelo de aprendizagem baseado no aprendizado humano [1].

Fazendo o uso de RNAs, o presente artigo trata do problema de classificação de Vinho. E este, é um conjunto de dados multivariado introduzido por *M. Florina*, o qual consiste em 178 amostras de 13 quesitos do vinho avaliado, pertencentes às três classes de vinho.

Estes dados são os resultados de uma análise química de vinhos cultivados na mesma região na Itália, no entanto, derivados de três diferentes cultivares. A análise determinou as quantidades de 13 constituintes encontrados em cada um dos três tipos de vinhos [2].

Desta forma, com base na combinação dessas 13 características, é possível classificar o tipo de vinho com base nas 178 amostras.

1.1 Metodologia

Para o fim proposto, foi usado o Software Matlab (R2018B), com o uso da toolbox de redes neurais.

1.2 Objetivos

Como objetivo geral, este trabalho implementa duas arquiteturas de Redes Neurais Artificiais para a classificação de três classes de vinho a partir dos 13 parâmetros de

entrada. A primeira arquitetura é uma RNA de Múltiplas Camadas (MLP) e a segunda, a uma MLP com estrutura Competitiva Auto Associativa.

Enquanto que o objetivo específico é averiguar e comparar a melhor arquitetura de rede para o problema de classificação proposto.

1.3 Organização do Trabalho

Este artigo está organizado como se segue. Na Seção 2 é feita uma revisão bibliográfica sobre Redes Neurais. Logo após, na Seção 3, é apresentada a base de dados estudada neste artigo. Na Seção 4 e na Seção 5, são apresentadas as arquiteturas das redes propostas, bem como por quais metodologias este trabalho se orienta. Os resultados são apresentados na Seção 6. Na Seção 7, as considerações finais desde trabalho.

2 REVISÃO BIBLIOGRÁFICA

Redes Neurais Artificiais são técnicas computacionais que apresentam um modelo matemático inspirado na estrutura neural de organismos inteligentes e que adquirem conhecimento através da experiência. A arquitetura base de rede neural estudada neste artigo é a Perceptron de Múltiplas Camadas (do inglês, Multilayer Perceptron, ou apenas MLP) [1] [3].

2.1 Perceptron de Multiplas Camadas

Uma rede MLP consiste em pelo menos três camadas: uma camada de entrada, uma camada oculta e uma

camada de saída. O MLP utiliza uma técnica de aprendizado supervisionada chamada *backpropagation* para o treinamento.

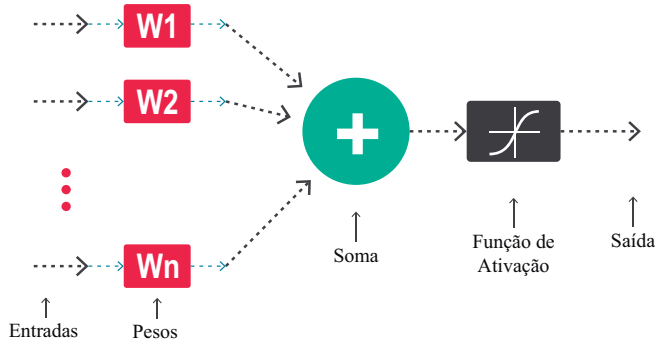


Figura 1. Arquitetura de uma rede MLP

A rede é alimentada pela camada de entrada, de maneira que as entradas serão ponderadas por pesos e, logo em seguida, serão somados de submetidos a uma função de ativação (na camada intermediária). Por fim, após este processamento, haverá uma resposta na camada de saída da rede, como ilustra a fig. 1.

2.2 Algoritmo Backpropagation

Quando verifica-se a resposta na camada de saída de uma MLP, podemos estimar o grau de acerto da rede. Portanto, há um valor esperado (e conhecido) para a resposta da rede durante a fase de treinamento. Logo, podemos extrair o erro dessa rede. O algoritmo *backpropagation* visa realimentar o erro nas entradas com o objetivo de minimizá-lo ao máximo. Essa característica é chamada de retropropagação do erro [1].

2.3 Estrutura Competitiva Auto Associativa

Redes neurais auto associativas são redes de *feedforward* treinadas para produzir uma aproximação do mapeamento de identidade entre entradas e saídas da rede usando o algoritmo *backpropagation* [4].




Figura 2. Arquitetura de uma rede auto associativa

O principal recurso de uma rede auto associativa é um gargalo dimensional entre entrada e saída (uma vez

que as camadas de entrada e saída são as mesmas e o número de neurônio na camada intermediária é inferior aos da entrada/saída). A compactação de informações pelo gargalo resulta na aquisição de um modelo de correlação dos dados de entrada, útil para executar uma variedade de tarefas de triagem de dados.

3 BASE DE DADOS

A base de dados tratada neste trabalho é referente a 13 parâmetros (características) de três classes de vinho, onde totaliza 178 instâncias de dados coletados. Os parâmetros são resultados de uma análise química das três classes de vinhos, a saber: álcool, ácido málico, cinza, alcalinidade das cinzas, magnésio, fenóis totais, flavinóides, fenóis não-flavonóides, proantocianinas, intensidade de cor, matiz, OD280/OD315 de vinho diluídos e prolina [2].

Tabela 1
Distribuição da base de dados

Classe	Treino	Validação	Teste	Total
1	39	10	10	59
2	51	10	10	71
3	28	10	10	48

Das 178 instâncias 59 pertencem à classe 1, 71 pertencem à classe 2 e 48 à classe 3, como mostra a tabela 1.

4 DESENVOLVIMENTO DA REDE MLP

A rede MLP foi implementada utilizando 13 neurônio na camada de entrada, 5 neurônio na camada intermediária e um neurônio na camada de saída.

A topologia da rede foi escolhida variando-se o número de neurônios na camada intermediária e fazendo um estudo sobre o erro médio quadrático (do inglês, MSE) e o número de erros na classificação.

Tabela 2
Melhor topologia MLP

NEURÔNIOS	MSE	ERROS
1	0.0705937829921329	3
3	0.0630764717369302	2
5	0.0157501702325207	1
10	0.0779010995153948	1
20	0.0883763713087734	2
40	0.155451160809213	6
80	0.158974910948916	5

A tabela 2 mostra o desempenho de cada topologia de rede MPL. Observa-se que o melhor desempenho foi obtido pela rede com 5 neurônios na camada intermediária, pois apresentou o menor erro médio quadrático e o menor número de erros na classificação.

4.1 Arquitetura MLP

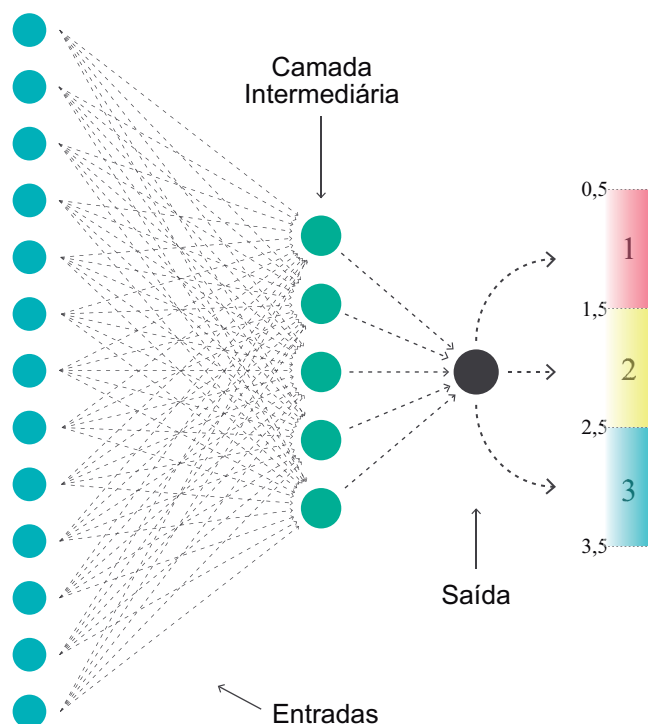


Figura 3. Arquitetura da rede MLP

A fig. 3 mostra a arquitetura da rede MPL. As 13 entradas alimentam os 5 neurônios na camada intermediária e, por conseguinte, a saída expressará um valor, que será alocado nos intervalos definidos na Seção 3.

Após a escolha da topologia da rede MLP, as entradas foram normalizadas no intervalo de 0 a 1.

4.2 Parâmetros de Classificação

A resposta da rede MLP foi definida em intervalos de abrangência. De 0,5 a 1,5, consideramos como pertencentes à classe 1. Os valores entre 1,5 a 2,5, são os da classe 2. Para a classe 3, foi definido o intervalo de 2,5 a 3,5.

5 DESENVOLVIMENTO DA REDE COMPETITIVA AUTO ASSOCIATIVA

A rede competitiva auto associativa é projetada sendo três redes, uma para cada classe, que serão treinadas para se especializarem na classe a qual elas representam. Assim, as três redes formam uma estrutura única de competição.

5.1 Arquitetura

A rede competitiva auto associativa foi implementada com 13 camadas de entrada e saída, sendo os seus argumentos os mesmos, e com 5 neurônios na camada intermediária, como mostra a fig. 4.




Figura 4. Arquitetura da rede Competitiva Auto Associativa

6 RESULTADOS

A mesma base de teste (sendo 10 de cada classe, totalizando 30) foi usada para verificar tanto o desempenho das 3 redes que compõe a auto associativa, quanto da rede MLP.

O parâmetro de comparação foi o erro médio quadrático (MSE) obtido no desempenho das redes.

6.1 Desempenho da Rede MLP

A rede MLP apresentou um desempenho bom, tendo em vista que houve apenas 1 erro na classificação.

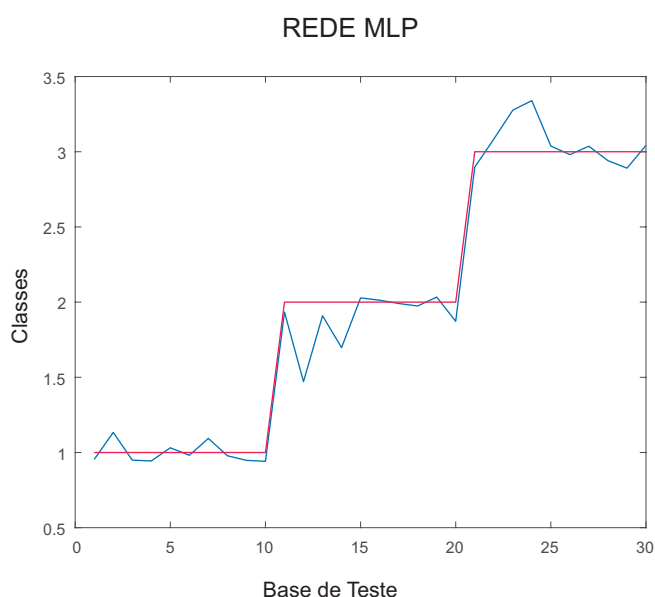


Figura 5. Saída da rede MLP

A fig. 5 mostra o desempenho da rede MLP, onde em azul é a saída da rede e em vermelho, a saída desejada.

6.2 Desempenho da Rede Auto Associativa

Considerando toda a base de teste (30 instâncias), as três redes que compõe a estrutura competitiva auto associativa apresentaram resultados bem interessantes para as classes nas quais elas são especializadas. No entanto, elas apresentaram erros consideráveis para as instâncias da base de teste pertencente às outras classes (o que de certa forma é esperado).

Tabela 3
Desempenho de classificação da rede auto associativa

TREINO	REDE 1	MSE REDE 2	REDE 3	CLASSIFICAÇÃO
1 a 10	8.5993e-06	0.000851717	0.0246367908	1 (100%)
11 a 20	2.7620175	8.67907e-19	1.5048243951	2 (100%)
21 a 30	0.253580	0.26402623	0.0003252681	3 (100%)

A Tabela 3 apresenta o desempenho geral da rede auto associativa. Quando a base de teste das três classes (30 instâncias) foram alimentadas na rede, houve 100% de acertos na classificação dos dados, onde cada rede especializada obteve os menores erros médios quadráticos (MSE) possíveis para as instâncias as quais lhe pertenciam de fato. Nas Considerações Finais (Seção 7) desse documento, fazemos uma discussão sobre a provável explicação para a rede auto associativa acertar em 100%.

6.2.1 Desempenho da Rede 1

A fig. 6 mostra o desempenho da rede 1, que é especializada na classe 1.




Figura 6. Desempenho da rede 1

Observa-se que o erro médio quadrático é extremamente baixo para a base de dados de 1 a 10 (que corresponde à classe 1) e bastante significativo entre 11 a 30, que são instâncias pertencentes às classes 2 e 3.

6.2.2 Desempenho da Rede 2

Na rede 2, o padrão de comportamento da rede 1 se repetiu. Observa-se que de 1 a 10 o MSE é acentuado, sendo extremamente baixo de 11 a 20 (instâncias pertencentes à classe 2), e novamente alto de 21 a 30, como mostrado na fig. 7.




Figura 7. Desempenho da rede 2

6.2.3 Desempenho da Rede 3

Seguindo a tendência de comportamento, a rede 3 apresentou um alto valor do MSE para as instâncias de 1 a 20 (pertencentes às classes 1 e 2), bem como um erro muito baixo para as instâncias da classe 3, onde a rede 3 é especializada, de 21 a 30.




Figura 8. Desempenho da rede 3

6.3 Comparação Rede MLP X Rede Auto Associativa

A tabela 4 mostra a comparação do erro médio quadrático das duas arquiteturas de rede.

Tabela 4
MLP X Auto Associativa

ARQUITETURA	ERRO MÉDIO QUADRÁTICO (MSE)	EFICIÊNCIA
MLP	0.0379018934769264	96.666%
AUTO ASSOCIATIVA	0.00033386747465863836	100%

A rede MPL errou apenas uma vez no processo de classificação. Enquanto que a Auto Associativa obteve 100% de acertos, bem como o menor erro médio quadrático (MSE).

7 CONSIDERAÇÕES FINAIS

7.1 Discussão

A proposta de uma Rede Neural especializada em cada classe confere um desempenho muito bom em problemas de classificação. Assim, em uma estrutura Competitiva Auto Associativa, o que se tem são três redes dedicadas a cada uma das classes. Diferentemente da Rede MLP, onde uma só rede tem o dever de classificar as três classes de vinho estudada.

7.2 Conclusão

As redes com estrutura Competitiva Auto Associativa demonstraram um desempenho significativamente maior frente à rede MPL. Portanto, a partir dos estudos das arquiteturas de redes neurais envolvidas neste trabalho, concluímos que as redes Auto Associativas têm uma grande confiabilidade para problemas de classificação. No entanto, deve-se ressaltar, que a base de dados estudada também apresenta uma certa facilidade para a classificação, já que a própria rede MLP errou uma única vez na topologia de neurônios. Certamente, essa facilidade da base de dados pode justificar a eficácia de 100% de acerto da rede auto associativa. Portanto, para problemas de classificação mais complexos, não necessariamente a eficácia de 100% de acertos se repetirá para uma estrutura competitiva auto associativa.

REFERÊNCIAS

- [1] Z. L. Kovács, *Redes neurais artificiais*. Editora Livraria da Física, 2002.
- [2] C. Fraley, A. E. Raftery, *et al.*, "Model-based methods of classification: using the mclust software in chemometrics," *Journal of Statistical Software*, vol. 18, no. 6, pp. 1–13, 2007.
- [3] S. Haykin, *Redes neurais: princípios e prática*. Bookman Editora, 2007.
- [4] V. Miranda, A. Castro, and S. Lima, "Diagnosing faults in power transformers with autoassociative neural networks and mean shift," *IEEE Transactions on Power Delivery - IEEE TRANS POWER DELIVERY*, vol. 27, pp. 1350–1357, 07 2012.